

Ajuste de curvas por Quadrados Mínimos Lineares / Regressão Linear

1. Introdução

Utilizamos este método quando temos uma distribuição de pontos (normalmente obtidos experimentalmente) e queremos ajustar a melhor curva que se aproxime de forma ótima a este conjunto de pontos, não necessariamente passando por todos eles.

2. Ajuste de Curvas por uma função linear


Inicialmente, vamos analisar o caso em que a curva de ajuste é uma função linear:

$$y_i = a_0 + a_1 x_i$$

Supondo que sejam p pontos tabelados, para que esta seja a reta que melhor se ajusta aos dados, devemos minimizar a soma das diferenças entre os valores de $f(x)$ tabelados y_i e os valores da curva de ajuste $a_0 + a_1 x_i$ em cada ponto. Ou seja, queremos minimizar o resíduo $r_i = y_i - (a_0 + a_1 x_i)$, $i = 1, 2, \dots, p$.


Entretanto, o resíduo pode tanto ser positivo quanto negativo, o que pode ocasionar uma soma nula das diferenças, mesmo com os valores muito distantes da reta.

- No exemplo abaixo, usando $\sum_{i=1}^p r_i$ o erro obtido é zero, mas isso se deve à anulação de termos com sinais opostos, e não a um melhor ajuste.



- Uma forma de evitar o cancelamento dos valores de sinais opostos é utilizar o módulo do resíduo $\sum_{i=1}^p |r_i|$. Entretanto, o módulo não garante uma solução única para os coeficientes da função, e por isso não pode ser utilizado para gerar o modelo de regressão. O exemplo seguinte mostra uma outra função que também


produz erro igual a 4 para o mesmo conjunto de dados.



Por isso minimizamos a soma dos quadrados dos resíduos. Definimos a função:

$$S(a_0, a_1) = \sum_{i=1}^p r_i^2 = \sum_{i=1}^p (y_i - (a_0 + a_1 x_i))^2$$

onde os resíduos são definidos por $r_i = y_i - (a_0 + a_1 x_i)$. A figura a seguir mostra o quadrado do resíduo nos pontos x_i :



O problema agora é encontrar valores de a_0 e de a_1 que minimizam $S(a_0, a_1)$. Para tanto, o gradiente de S (ou seja, a derivada primeira da função de duas variáveis $S(a, b)$) deve ser nulo.

$$\frac{\partial S}{\partial a_0} = 2 \sum_{i=1}^p (y_i - a_0 - a_1 x_i)(-1) = 0$$

$$\frac{\partial S}{\partial a_1} = 2 \sum_{i=1}^p (y_i - a_0 - a_1 x_i)(-x_i) = 0$$

Em notação matricial temos que

$$X = \begin{pmatrix} a_0 \\ a_1 \end{pmatrix}, Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{pmatrix}, R = \begin{pmatrix} r_1 \\ r_2 \\ \vdots \\ r_p \end{pmatrix}, A = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_p \end{pmatrix}$$

Como queremos minimizar

$$S(a, b) = R^T R, \text{ onde } R = Y - AX$$

basta resolvermos o sistema linear

$$A^T A X = A^T Y$$

Como a matriz $A^T A$ é simétrica definida positiva, o sistema linear admite solução única e esta solução será o ponto crítico que será o ponto de mínimo.

Efetuada os cálculos de $A^T A$ e de $A^T Y$ temos:

$$\begin{pmatrix} \sum_{i=1}^p 1 & \sum_{i=1}^p x_i \\ \sum_{i=1}^p x_i & \sum_{i=1}^p x_i^2 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^p y_i \\ \sum_{i=1}^p x_i y_i \end{pmatrix}$$

3. Ajuste de Curvas por Polinômios

Podemos generalizar este resultado para ajustarmos ajustar qualquer polinômio da forma

$$y = a_0 + a_1 x + \dots + a_n x^n$$

a um conjunto de p pontos (x_i, y_i) , minimizando o quadrado do resíduo r_i . Definindo

$$S(a_0, a_1, \dots, a_n) :$$

$$S(a_0, a_1, \dots, a_n) = \sum_{i=1}^p r_i^2 = \sum_{i=1}^p (y_i - (a_0 + a_1 x_i + \dots + a_n x_i^n))^2$$

O ponto mínimo de $S(a_0, a_1, \dots, a_n)$ é aquele para o qual a derivada é zero. Portanto podemos obter as seguintes equações, derivando S em relação a cada uma de suas variáveis:

$$\begin{aligned}\frac{\partial S}{\partial a_0} &= \sum_{i=1}^p 2(y_i - a_0 - a_1 x_i - \dots - a_n x_i^n)(-1) = 0 \\ \frac{\partial S}{\partial a_1} &= \sum_{i=1}^p 2(y_i - a_0 - a_1 x_i - \dots - a_n x_i^n)(-x_i) = 0 \\ &\vdots \\ \frac{\partial S}{\partial a_n} &= \sum_{i=1}^p 2(y_i - a_0 - a_1 x_i - \dots - a_n x_i^n)(-x_i^n) = 0\end{aligned}$$

Colocando estas equações em notação matricial temos:

$$X = \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix}, Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{pmatrix}, R = \begin{pmatrix} r_1 \\ r_2 \\ \vdots \\ r_p \end{pmatrix}, A = \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^n \\ 1 & x_2 & x_2^2 & \cdots & x_2^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_p & x_p^2 & \cdots & x_p^n \end{pmatrix}$$

Então, para encontrarmos os pontos $a_0, a_1, \dots, a_n$, temos que resolver o sistema linear $A^T A X = A^T Y$. Efetuando os cálculos de $A^T A$ e de $A^T Y$, temos o seguinte sistema linear em forma matricial:

$$\begin{pmatrix} \sum_{i=1}^p x_i^0 & \sum_{i=1}^p x_i^1 & \cdots & \sum_{i=1}^p x_i^n \\ \sum_{i=1}^p x_i^1 & \sum_{i=1}^p x_i^2 & \cdots & \sum_{i=1}^p x_i^{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^p x_i^n & \sum_{i=1}^p x_i^{n+1} & \cdots & \sum_{i=1}^p x_i^{2n} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^p x_i^0 y_i \\ \sum_{i=1}^p x_i^1 y_i \\ \vdots \\ \sum_{i=1}^p x_i^n y_i \end{pmatrix}$$

Este procedimento pode ser generalizado para qualquer curva de ajuste da forma:

$$y = a_0 g_0(x) + \dots + a_n g_n(x)$$

desde que as funções $g_i(x)$ avaliadas nos pontos resultem em vetores linearmente independentes, que é uma condição necessária para que a matriz $A^T A$ seja invertível.

3.1. Exercício

Dados um conjunto de p pontos (x_i, y_i) e o grau n de um polinômio que aproxima estes pontos, escreva um procedimento para calcular a matriz de coeficientes e o vetor de termos independentes do sistema linear que deve ser resolvido.

```
/*
  xy: vetor bidimensional com p elementos, contendo sequência de pares
      [xi,yi]
  ATA: matriz de tamanho n+1 x n+1 para os coeficientes do S.L.
        (previamente inicializado em 0)
  ATY: matriz de tamanho n+1 x 1 para os termos independentes do S.L.
        (previamente inicializado em 0)
  p: número de pontos
  n: grau do polinômio
*/
calculaATAeATY(double *xy, double **ATA, double *ATY, int p, int n)
{
}
```

- Observar a repetição dos termos na matriz de coeficientes e termos independentes
- Atentar para o reaproveitamento da cache
- O importante é otimizar o acesso em função de p e não de n

3.2. Um exemplo de aplicação do método de quadrados mínimos

Podemos usar o método dos quadrados mínimos para ajustar uma curva aos dados da população brasileira entre os anos de 1872 e 1996; com isso podemos prever qual será a população em um ano posterior.

Considere a tabela abaixo da população brasileira (em milhões):

ano	1872	1890	1900	1920	1940	1950	1960	1970	1980	1991	1996
população	9.9	14.3	17.4	30.6	41.2	51.9	70.2	93.1	119.0	146.2	157.1

Vamos ajustar uma curva da forma de um polinômio de segundo grau $y = a + bx + cx^2$ onde y denota a população e x o ano. De posse da tabela podemos construir um sistema cuja solução é: $a = 46044.8$, $b = -48.7163$, $c = 0.0128889$

Daí podemos calcular a população em 2000 calculando $y(2000) = 167.9$, cujo valor podemos comparar com os dados oficiais do IBGE que informa que a população brasileira em 2000 era de 169.8 milhões de habitantes.

Ajustando um polinômio de segundo grau pelo método dos quadrados mínimos conseguimos uma previsão para a população em 2000 que difere da real em 1.1%.

4. Ajuste de curvas por funções não-lineares

Muitas vezes a função que melhor se ajusta aos dados não é linear nos parâmetros. Em casos assim é muito útil transformar os dados de forma a obter uma regressão linear. Isto pode ser feito para modelos exponenciais, potências e crescimento.

4.1. Modelo Exponencial

Diversos processos físicos e químicos são governados por funções exponenciais..

$$y = ae^{bx}$$

Aplicando o logaritmo neperiano em ambos os lados da Equação obtemos

$$\ln(y) = \ln(a) + bx$$

Seja

$$z = \ln(y)$$

$$a_0 = \ln(a) \quad \text{implicando em} \quad a = e^{a_0} \quad a_1 = b$$

então

$$z = a_0 + a_1 x$$

4.2. Modelo de Potência

A equação de potência descreve diversos fenômenos científicos e de engenharia:

$$y = ax^b$$

O método dos quadrados mínimos é aplicado à função de potência ao linearizar os dados (a hipótese é que b é desconhecido).

$$\ln(y) = \ln(a) + b \ln(x)$$

Seja

$$z = \ln(y)$$

$$w = \ln(x)$$

$$a_0 = \ln(a) \quad \text{implicando em} \quad a = e^{a_0} \quad a_1 = b$$

então

$$z = a_0 + a_1 w$$

4.3. Modelo de Crescimento

Modelos de crescimento são usados para modelar a taxa de crescimento em função de uma variável regressora (geralmente o tempo). Exemplos incluem o crescimento populacional em função do tempo, e podem ser modelados pela equação

$$y = \frac{ax}{b+x}$$

Para $x=0$, $y=0$ enquanto que para $x \rightarrow \infty$, $y \rightarrow a$. Para linearizar os dados neste método,

$$\frac{1}{y} = \frac{b+x}{ax} = \frac{b}{a} \frac{1}{x} + \frac{1}{a}$$

Seja

$$z = \frac{1}{y}, \quad w = \frac{1}{x},$$

$$a_0 = \frac{1}{a} \quad \text{implicando em} \quad a = \frac{1}{a_0}$$

$$a_1 = \frac{b}{a} \quad \text{implicando em} \quad b = a_1 \times a = \frac{a_1}{a_0}$$

Então

$$z = a_0 + a_1 w$$

4.4. Exemplo de Função exponencial

Vamos agora tentar ajustar aos mesmos pontos do exemplo anterior uma função do tipo $y(x) = a e^{bx}$. Neste caso a curva de ajuste não é linear nos parâmetros a, b e para aplicar o procedimento dos quadrados mínimos lineares devemos linearizar a curva de ajuste. Isto pode ser feito aplicando-se o logaritmo na expressão acima, obtendo $\ln(y) = \ln a + b x$ implicando em $a = e^{a_0}$ e $b = a_1$.

Portanto calculamos $\ln(y)$, e com isso ajustamos uma reta aos pontos $(x, \ln(y))$ pelo método dos quadrados mínimos. Note que os parâmetros a e b encontrados não são os que minimizam a função $S(a, b) = \sum_{i=1}^p (y_i - a e^{bx})^2$, mas os que minimizam a função

$$G(a_0, a_1) = \sum_{i=1}^p (\ln y_i - a_0 + a_1 x_i)^2$$

ano	1872	1890	1900	1920	1940	1950	1960	1970	1980	1991	1996
popul	9.9	14.3	17.4	30.6	41.2	51.9	70.2	93.1	119.0	146.2	157.1
ln(popul)	2.29253	2.66026	2.85647	3.421	3.71844	3.94932	4.25135	4.53367	4.77912	4.98498	5.05688

Construindo a matriz A e os vetores X e Y e resolvendo o sistema temos como solução o $\ln(y) = -40.4266 + 0.0227992x$. Aplicando a função exponencial temos: $y = 2.77287 \times 10^{-18} e^{0.0227992x}$.

Calculando o valor dessa função no ponto 2000 temos $y(2000) = 176.2$, cujo erro percentual comparado com os dados do IBGE é de 3.7%.

Neste exemplo, quando ajustamos por uma função exponencial, conseguimos ajustar melhor os pontos iniciais, já no caso de uma parábola, conseguimos ajustar melhor os pontos finais da tabela. Em ambos os casos, podemos calcular o resíduo, dado pela norma L_2 do vetor formado pela diferença entre o valor real e o valor calculado pela função obtida para cada ponto. Para a parábola temos que o resíduo é 14.2. Já para a

exponencial temos que o resíduo é -11.45 .

Note que apesar do resíduo da exponencial ter sido menor do que o resíduo da parábola, a previsão feita pela parábola para o ano de 2000 foi melhor do que a da exponencial, portanto a maneira como a curva se ajusta aos pontos tabelados não diz nada a respeito da maneira como essa curva fará previsões para outros pontos.